

Laboratorio 2: Modelos LSTM para Series de Tiempo del Flujo Turístico a Guatemala (2009–2026)

Osman de León
Milton Polanco

30 de julio de 2026

Resumen

Este informe extiende el análisis del Laboratorio 1 mediante la aplicación de redes neuronales recurrentes LSTM (*Long Short-Term Memory*) a dos series del flujo turístico hacia Guatemala: el Total Mensual de Viajeros y la región América del Norte. Se diseñó un espacio de búsqueda de seis configuraciones (arquitecturas simple y apilada, variando ventana de entrada, unidades, *dropout*, tasa de aprendizaje y tamaño de lote), seleccionando la mejor configuración mediante validación temporal. Los resultados se compararon contra los modelos clásicos del Laboratorio 1 (SARIMA y Prophet), encontrándose que estos últimos siguen siendo más precisos dado el volumen limitado de observaciones disponible. En una segunda parte, se empleó **catch22** —un conjunto de 22 características descriptivas de series de tiempo— para analizar la similitud entre las 7 series definidas en el Laboratorio 1 mediante PCA, *clustering* jerárquico y K-Means, y se evaluó si enriquecer al LSTM con dichas características mejoraba su desempeño.

1. Introducción

En el Laboratorio 1 se compararon cinco familias de modelos clásicos de series de tiempo (SARIMA, Facebook Prophet, Holt-Winters, Suavizamiento Exponencial Simple y Seasonal Naive) sobre 7 series mensuales del flujo turístico a Guatemala. En este laboratorio se retoman dos de esas series —el Total Mensual de Viajeros y la región América del Norte— para explorar un enfoque de *deep learning*: redes LSTM. El objetivo es doble: (1) determinar si una arquitectura de aprendizaje profundo logra superar a los modelos estadísticos clásicos bajo el mismo esquema de evaluación, y (2) utilizar **catch22** para caracterizar y comparar objetivamente las 7 series del laboratorio anterior.

2. Preparación de los Datos

Se utilizó el mismo filtro del Laboratorio 1 (consolidación de las categorías Turista + Excursionista) y se conservó la división cronológica de **70 % para entrenamiento y 30 % para prueba** (147 observaciones de entrenamiento, de enero de 2009 a marzo de 2021, y 63 de prueba, de abril de 2021 a junio de 2026). Mantener el mismo esquema de partición permite comparar directamente los resultados con los modelos del Laboratorio 1.

3. Modelos y Tuneo de Parámetros

Se evaluaron dos arquitecturas: una **LSTM simple**, con una capa recurrente, y una **LSTM apilada**, con dos capas recurrentes. Dentro de ambas se modificó la ventana de entrada, la cantidad

de unidades, el *dropout*, la tasa de aprendizaje y el tamaño de lote, para un total de seis configuraciones (Cuadro 1). El último 20 % de las secuencias de entrenamiento se utilizó como validación temporal: las observaciones no se revolvieron y el conjunto de prueba no se utilizó para escoger la configuración.

Cuadro 1: Espacio de búsqueda de configuraciones LSTM evaluadas.

Config.	Arquitectura	Ventana	Unidades	Dropout	LR / Batch
simple_01	simple	6	32	0.10	0.0010 / 16
simple_02	simple	12	32	0.20	0.0010 / 16
simple_03	simple	12	64	0.20	0.0005 / 8
apilada_01	apilada	6	64–32	0.10	0.0010 / 16
apilada_02	apilada	12	64–32	0.20	0.0010 / 16
apilada_03	apilada	12	32–16	0.20	0.0005 / 8

3.1. Resultados del tuneo

Cada configuración se ajustó por separado y los resultados se ordenaron según el RMSE de validación (Cuadro 2). En ambas series, la configuración ganadora fue la **LSTM apilada (apilada_01)**: ventana de seis meses, 64 unidades en la primera capa, 32 en la segunda y *dropout* de 0.10.

Cuadro 2: RMSE de validación por configuración y serie.

Serie	Configuración	RMSE validación
Total mensual de viajeros	simple_01	116,736
Total mensual de viajeros	simple_02	143,462
Total mensual de viajeros	simple_03	128,083
Total mensual de viajeros	apilada_01	114,971
Total mensual de viajeros	apilada_02	131,048
Total mensual de viajeros	apilada_03	135,658
Región: América del Norte	simple_01	19,052
Región: América del Norte	simple_02	21,586
Región: América del Norte	simple_03	19,795
Región: América del Norte	apilada_01	18,078
Región: América del Norte	apilada_02	20,050
Región: América del Norte	apilada_03	20,321

4. Predicción con el Mejor Modelo

Para cada serie se tomó la configuración con menor RMSE de validación. Luego se entrenó nuevamente con todas las observaciones de entrenamiento y se pronosticaron los 63 meses de prueba de manera recursiva (Figura 1 y Figura 2).




Figura 1: Series utilizadas (Total Mensual y América del Norte) con la división entrenamiento/prueba.




Figura 2: Pronóstico recursivo del mejor modelo LSTM (apilada_01) en el conjunto de prueba.

5. Resultados Preliminares

El Cuadro 3 resume el desempeño del mejor modelo LSTM por serie sobre el conjunto de prueba (63 meses).

Cuadro 3: Métricas del mejor modelo LSTM en el conjunto de prueba.

Serie	Config.	MAE	RMSE	sMAPE (%)
Total mensual de viajeros	apilada_01	74,089.96	85,804.50	34.39
Región: América del Norte	apilada_01	26,247.47	30,752.14	54.87

El pronóstico sigue la recuperación general posterior a 2021, pero suaviza los picos mensuales. Esto ocurre porque se pronostican 63 meses de forma recursiva a partir de un entrenamiento que termina durante la pandemia.

6. Comparación con los Modelos del Laboratorio 1

En el Laboratorio 1 se compararon SARIMA, Facebook Prophet, Holt-Winters, SES y Seasonal Naive para las 7 series. Para las dos series trabajadas aquí, los mejores modelos clásicos fueron los que se muestran en el Cuadro 4, contrastados contra el mejor modelo LSTM (`apilada_01`) de este laboratorio.

Cuadro 4: Comparación: mejor modelo clásico (Laboratorio 1) vs. mejor LSTM (Laboratorio 2).

Serie	Modelo	MAE	RMSE
Total mensual de viajeros	SARIMA(1,1,1)(1,1,1) ₁₂	18,421.30	23,150.45
Total mensual de viajeros	LSTM <code>apilada_01</code>	74,089.96	85,804.50
Región: América del Norte	Facebook Prophet	5,120.30	6,840.15
Región: América del Norte	LSTM <code>apilada_01</code>	26,247.47	30,752.14

¿Cuál predijo mejor? ¿Son mejores los LSTM que los modelos del Laboratorio 1?

No. En ambas series, los modelos del Laboratorio 1 obtuvieron mejores resultados que los LSTM. La comparación se hizo utilizando el mismo conjunto de prueba (abril de 2021 a junio de 2026) y las mismas métricas (MAE y RMSE), por lo que los resultados son directamente comparables. Esto se atribuye principalmente a tres razones:

1. **Pocos datos para entrenar la LSTM.** Con solo 147 observaciones de entrenamiento, la red no tiene suficiente información para aprender patrones complejos y termina generando predicciones más suaves.
2. **El pronóstico es recursivo.** Cada predicción se utiliza para calcular la siguiente, por lo que pequeños errores se acumulan a lo largo de los 63 meses pronosticados.
3. **Los modelos clásicos aprovechan mejor la estructura de la serie.** SARIMA y Prophet representan explícitamente la tendencia y la estacionalidad, mientras que la LSTM debe aprender esos patrones únicamente a partir de los datos.

Además, el cambio tan fuerte provocado por la pandemia dificulta que la red generalice correctamente ese comportamiento. En síntesis: con el volumen de datos disponible (210 meses), los modelos estadísticos clásicos siguen siendo más precisos que las LSTM para estas series. Esto no invalida el enfoque de *deep learning*, pero sí muestra que su ventaja teórica (capturar no linealidades) requiere más historia de la que se tiene aquí para materializarse.

7. Ejercicio 2. Similitud de las Series mediante *catch22*

7.1. ¿Qué es *catch22* y por qué importa?

catch22 es un conjunto de 22 características que resumen el comportamiento de una serie de tiempo, describiendo aspectos como la autocorrelación, la estacionalidad, la variabilidad, la distribución de los valores y otros patrones relevantes. Su principal ventaja es que permite representar cada serie mediante un vector de características, independientemente de su escala o magnitud, lo cual facilita compararlas entre sí y aplicar técnicas como PCA, *clustering* o medidas de distancia. En este laboratorio, *catch22* permitió analizar qué series tienen comportamientos similares y cuáles son diferentes, complementando el análisis exploratorio del Laboratorio 1 con una comparación más objetiva.

7.2. Construcción de las 7 series y extracción de *catch22*

Se reconstruyeron las 7 series especificadas en el Laboratorio 1: la serie obligatoria (Total mensual de viajeros), 3 regiones geográficas (América del Centro, América del Norte, Europa) y 3 países de residencia (El Salvador, Guatemala, Estados Unidos de América), usando el mismo filtro Turista + Excursionista. Para cada serie se extrajeron las 22 características de *catch22* sobre su historia completa (2009–2026), dado que el objetivo es comparar la *forma* global de cada serie, no predecir.

Nota: la serie País: Guatemala (guatemaltecos residentes en el exterior) solo tiene datos hasta 2022-12 (168 observaciones), consistente con lo documentado en el Laboratorio 1: el cambio de criterio de registro entre 2022 y 2023 dejó de capturar esta categoría bajo la definición Turista/Excursionista. *catch22* no requiere que todas las series tengan la misma longitud, por lo que esto no afecta la comparación.

7.3. Estandarización y análisis exploratorio de la matriz *catch22*

Las 22 características se estandarizaron (media 0, varianza 1) antes de aplicar PCA y *clustering*, para que ninguna característica domine por su escala.




Figura 3: Proyección PCA de las 7 series sobre el espacio de características catch22.




Figura 4: *Clustering* jerárquico y K-Means de las 7 series.




Figura 5: Heatmap de las 22 características catch22 estandarizadas por serie.




Figura 6: Matriz de correlación entre las 22 características catch22.




Figura 7: Mapa de distancias entre las 7 series en el espacio catch22.

7.4. Análisis e interpretación

¿Cuáles series presentan comportamientos más similares? El PCA y el mapa de distancias muestran dos grupos principales. El primero está formado por Total mensual de viajeros, América del Centro, El Salvador y Guatemala, mientras que el segundo incluye América del Norte, Europa y Estados Unidos. La serie Total es la más parecida a América del Centro, lo cual tiene sentido porque esta región aporta la mayor parte del flujo de viajeros. De igual forma, América del Norte y Estados Unidos aparecen muy cerca entre sí. Tanto el *clustering* jerárquico como K-Means confirman esta misma agrupación.

¿Qué características fueron más importantes para diferenciar las series? Las características con mayor peso están relacionadas con la persistencia, la autocorrelación y el comportamiento de las fluctuaciones de las series, mientras que otras describen la periodicidad y la memoria de corto plazo. En conjunto, esto indica que las diferencias entre las series dependen más de su comportamiento en el tiempo que del número de viajeros que registran.

¿Existen grupos naturales de series? Sí. La partición con dos grupos fue la que mejor representó los datos y coincide con lo observado en el PCA. Al aumentar el número de grupos, Guatemala y luego El Salvador comienzan a separarse, indicando que presentan características propias dentro de su grupo.

¿Las series de una misma categoría tienden a agruparse? No necesariamente. Las regiones no quedaron juntas y ocurrió lo mismo con los países. Esto muestra que catch22 agrupa las series según su comportamiento temporal, más que por su categoría geográfica. Series de categorías diferentes pueden ser similares si presentan patrones parecidos de tendencia, estacionalidad y variabilidad.

Serie con el comportamiento más atípico. La serie de Guatemala fue la más diferente del conjunto. Presentó las mayores distancias respecto a las demás y fue la primera en separarse al

aumentar el número de grupos, resultado que coincide con el Laboratorio 1, donde también mostró la mayor variabilidad.

Consistencia con el análisis exploratorio del Laboratorio 1. En general, los resultados son consistentes con el análisis anterior. La serie Total, América del Centro y El Salvador vuelven a aparecer relacionadas por su marcada estacionalidad, mientras que América del Norte, Europa y Estados Unidos presentan un comportamiento más similar entre sí. Guatemala continúa destacando por su mayor variabilidad. Además, aunque la pandemia afectó todas las series, catch22 parece dar mayor importancia al comportamiento general de largo plazo que a ese evento puntual.

Hallazgos no evidentes en el análisis exploratorio tradicional:

- La serie Total es más parecida a América del Centro y El Salvador que a América del Norte.
- Las categorías geográficas no determinan los grupos; la dinámica temporal tiene mayor influencia.
- La persistencia y la autocorrelación explican mejor las diferencias entre las series que el impacto de la pandemia.

8. Nuevo Modelo LSTM usando Características de catch22

Se construyó un tercer modelo LSTM utilizando la misma arquitectura que obtuvo los mejores resultados anteriormente (**apilada_01**: LSTM 64→LSTM 32, ventana de 6 meses y *dropout* de 0.10) sobre la serie Total mensual de viajeros. La diferencia es que, además del valor de la serie en cada mes, se agregaron las 22 características de catch22 calculadas a partir del conjunto de entrenamiento, de forma que cada entrada del modelo incluye tanto el valor de la serie como información adicional sobre su comportamiento general.

Cuadro 5: LSTM con valores crudos vs. LSTM + catch22 estático (serie Total mensual de viajeros).

Modelo	MAE	RMSE	Diferencia RMSE
LSTM apilada_01 (valores crudos)	74,089.96	85,804.50	0.00
LSTM apilada_01 + catch22 estático	73,957.07	85,625.35	-179,15




Figura 8: Pronóstico en prueba: LSTM con valores crudos vs. LSTM + catch22 estático.

Discusión de resultados

Agregar las características de catch22 al modelo LSTM produjo un resultado muy parecido al obtenido usando únicamente la serie original: la diferencia en las métricas fue mínima, por lo que no se observó una mejora importante en las predicciones. Esto puede explicarse porque el vector de catch22 se calcula una sola vez sobre los datos de entrenamiento y luego se repite en todas las ventanas, por lo que aporta información sobre el comportamiento general de la serie, pero no sobre los cambios que ocurren mes a mes durante el pronóstico.

Además, el principal problema ya identificado en la sección de comparación con el Laboratorio 1 sigue siendo el mismo: el modelo cuenta con pocos datos de entrenamiento y debe realizar un pronóstico recursivo de muchos pasos, por lo que el error se va acumulando. Agregar más características no resuelve esas limitaciones. También se probó utilizar únicamente características de catch22 calculadas sobre ventanas móviles, pero los resultados fueron inestables, ya que pequeños errores en las primeras predicciones terminaban afectando las siguientes ventanas y degradaban el desempeño del modelo.

Para este conjunto de datos, catch22 resultó más útil para comparar y analizar las series temporales que para mejorar el desempeño del modelo LSTM. El factor que más limita las predicciones sigue siendo la cantidad de datos disponibles y la acumulación de error durante el pronóstico recursivo.

9. Conclusiones

1. Bajo el mismo esquema de partición y métricas del Laboratorio 1, los modelos clásicos (SARIMA, Prophet) superaron consistentemente a las redes LSTM, principalmente por la escasez de datos de entrenamiento y la acumulación de error en el pronóstico recursivo.
2. catch22 permitió caracterizar objetivamente las 7 series del Laboratorio 1, revelando dos grupos naturales de comportamiento que no coinciden necesariamente con las categorías geográficas originales.
3. Enriquecer al LSTM con características catch22 estáticas no generó mejoras relevantes en la precisión del pronóstico, confirmando que el factor limitante es la cantidad de historia disponible y no la falta de información descriptiva sobre la serie.